Predikcija prodajne cene nekretnina primenom Random Forest i XGBoost modela

Luka Šarić E2 68/2025 Srđan Perišić E2 102/2025 Petar Milinković E2 111/2025

Fakultet tehničkih nauka, Novi Sad, 2026

Apstrakt

Procena tržišne vrednosti nekretnina predstavlja izazovan problem zbog složenih, nelinearnih odnosa između cenovnih determinanti kao što su površina, lokacija i stanje objekta. U ovom radu razvijamo i upoređujemo modele mašinskog učenja za predikciju prodajne cene stambenih nekretnina (eng. real estate price prediction) na beogradskom tržištu. Skup podataka obuhvata 9.619 oglasa prikupljenih sa srpskog portala za prodaju nekretnina, koji su nakon postupka čišćenja i uklanjanja ekstremnih vrednosti svedeni na 8.804 validne instance. U procesu pripreme podataka primenjena je geokodizacija lokacija, izvođenje atributa distance do centra Beograda, kao i binarno kodiranje tipa grejanja. Izvršeno je poređenje četiri modela: linearne regresije, stabla odlučivanja, Random Forest-a i XGBoost-a. Optimizacijom hiperparametara postignut je podjednak učinak oba ansambl modela sa vrednošću koeficijenta determinacije $R^2 = 0,87$ na test skupu. Analiza važnosti atributa konzistentno identifikuje površinu (eng. square footage) i udaljenost od centra kao dominantne prediktore cene. Rezultati potvrđuju superiornost ansambl metoda u odnosu na linearne modele i ukazuju na značaj geografskog konteksta u modelovanju tržišta nekretnina.

Ključne reči: *predikcija cena nekretnina, Random Forest, XGBoost, mašinsko učenje, beogradsko tržište, geokodizacija*

1. Uvod

Tržište nekretnina predstavlja jedan od ekonomski najznačajnijih sektora u svakom savremenom društvu. Tačna i pravovremena procena tržišne vrednosti nekretnine od suštinskog je značaja za različite aktere, od kupaca i prodavaca koji nastoje da donese racionalne poslovne odluke, do banaka koje procenjuju kreditne rizike, investitora koji planiraju portfolije i regulatornih tela koja prate kretanje cena na tržištu. Tradicionalne metode procene, kao što su hedonistički modeli i višestruka linearna regresija (eng. multiple linear regression), dugo su bile dominantni alat u praksi. Međutim, ove metode počivaju na pretpostavci o linearnosti odnosa između cene i njenih determinant, pretpostavci koja se u realnim podacima često ne može održati.

Beogradsko tržište nekretnina karakterišu naročito izražene nelinearnosti: cena po kvadratnom metru može se naglo menjati na kratkim rastojanjima, pri čemu prestiž mikrolokacije (blizina centru, infrastrukturne tačke, saobraćajne veze) ima nesrazmeran uticaj koji nije moguće adekvatno modelovati linearnom funkcijom. Linearna regresija pruža dobru polaznu tačku, ali ne uspeva da modeluje ove efekte kao na primer, nekretnine u centralnim četvrtima (Stari Grad, Vračar, Savski venac) postižu cene višestruko iznad perifernih, a ta razlika nije samo posledica veće površine. Zbog toga su u ovom radu primenjena ansambl stabla odlučivanja koja prirodno detektuju takve interakcije i pragove u podacima.

Savremene metode mašinskog učenja, posebno Random Forest [1] i XGBoost [2], demonstriraju sposobnost modelovanja nelinearnih zavisnosti, interakcija između atributa i heterogenih tržišnih uslova. Random Forest kao bagging metoda smanjuje varijansu agregiranjem stotina stabala, što ga čini robusnim na šum prisutan u podacima iz oglasa. XGBoost kao boosting metoda iterativno koriguje preostale greške prethodnih modela, pa posebno dobro hvata suptilne nelinearne signale, na primer, da je prisustvo lifta jači prediktor u kombinaciji sa visokim spratom, nego izolovano. Obe osobine su motivacijski vezane za karakteristike ovog skupa podataka.

Ovaj rad ima sledeće ciljeve: (1) prikupiti i pripremiti realan skup podataka o prodajnim oglasima stambenih nekretnina u Beogradu, (2) sprovesti eksploratorijalnu analizu podataka (eng. exploratory data analysis, EDA) radi razumevanja distribucija i međusobnih odnosa varijabli, (3) izgraditi i optimizovati modele linearne regresije, stabla odlučivanja, Random Forest-a i XGBoost-a, te (4) uporediti njihove performanse koristeći standardne metrike evaluacije. Poseban naglasak stavlja se na obogaćivanje podataka geokodizacijom lokacija i derivacijom obeležja distance, kao i na analizu važnosti atributa radi interpretabilnosti modela.

2. Pregled relevantne literature

U dosadašnjoj literaturi postoji značajan broj radova koji se bave primenom mašinskog učenja za predikciju cena nekretnina, kako na globalnom nivou, tako i na tržištu u regionu. U nastavku su opisani radovi koji su direktno uticali na metodološke odluke u ovom projektu.

Rad Housing price prediction using XGBoost and Random Forest methods [4] direktno je relevantan jer autori primenjuju iste algoritme na beogradskom tržištu, koristeći skup od 1.104 oglasa. Postignut je XGBoost MAE od 17.431,69 EUR i MAPE od 11,61%, dok je Random Forest postigao MAE od 17.857,81 EUR i MAPE od 12,02%. Naš skup podataka je oko osam puta veći (8.804 instance), što je motivisalo proveru da li se tačnost dodatno poboljšava sa više podataka, i da li XGBoost zadržava prednost na većim skupovima.

Istraživanje Estimating the Performance of Random Forest versus Multiple Regression for Predicting Prices of Apartments [5] upoređuje OLS regresiju i Random Forest na 7.407 transakcionih zapisa iz Ljubljane. Random Forest ostvaruje MAPE od 7,27% nasuprot 17,48% kod OLS-a, razlika koja direktno govori o tome koliko nelinearne zavisnosti u cenovnom prostoru nekretnina nisu uhvaćene linearnim modelima. Autori naglašavaju značaj uvođenja prostornih promenljivih. Upravo ovaj nalaz motiviše naše uvođenje distance do centra Beograda i koordinata kao posebnih atributa, umesto oslanjanja isključivo na kategorijsku mikrolokaciju.

Pregled Predicting real estate prices with machine learning [6] opisuje ansambl paradigme: bagging (Random Forest) smanjuje varijansu agregiranjem stabala, dok boosting (XGBoost) iterativno fokusira sledeće stablo na greške prethodnog. Ovaj konceptualni okvir pomaže da se razume zašto oba modela postižu slične ukupne rezultate ali drugačiju raspodelu važnosti atributa - što je vidljivo i u našoj analizi.

Rad The Use of Machine Learning in Real Estate Research [7] daje širi pregled primene ML-a u domenu nekretnina i ističe lokacijske i infrastrukturne faktore kao ključne prediktore vrednosti. Ova napomena je uticala na odluku da se geokodizuju mikrolokacije i izvede distanca do centra, umesto da se oslonimo samo na kategorijski atribut ulice koji model ne može interno geografski urediti.

3. Skup podataka i obrada podataka

3.1. Opis skupa podataka

Inicijalni skup podataka prikupljen je veb skrejpingom (eng. web scraping) sa srpskog portala za prodaju nekretnina i sadrži 9.619 oglasa stambenih nekretnina sa 10 atributa. Ciljna promenljiva je prodajna cena izražena u evrima (Price_EUR). Ulazna obeležja obuhvataju:

- Numerička: površina u kvadratnim metrima, broj soba, etaža (sprat)
- Binarna: lift (da/ne), optički internet (da/ne), parking (da/ne)
- Kategorijska: tip grejanja (višestruki izbor), stanje objekta, ulica/mikrolokacija

Tabela 1 prikazuje pregled inicijalnih karakteristika skupa podataka.

Atribut	Tip	Nedostajući	Opis
Price_EUR	float64	43 (0,45%)	Cena u evrima - ciljna promenljiva
Square_footage	object → float	16 (0,17%)	Površina u m²
Number_of_rooms	float64	127 (1,32%)	Broj soba
State	object	162 (1,68%)	Stanje/tip gradnje
Heating	object	790 (8,21%)	Tip grejanja (višestruki izbor)
Lift / Parking / Optical_internet	int64	0	Binarne karakteristike
Floor	object → float	0	Etaža (sprat)
Street	object	0	Mikrolokacija / naziv ulice

Tabela 1. Pregled atributa inicijalnog skupa podataka.

3.2. Čišćenje i tretman nedostajućih vrednosti

Atributi sa nedostajućim vrednostima tretirani su na sledeći način. Oglasi bez cene ili površine uklanjeni su iz skupa (redovi su obrisani), jer ove dve promenljive čine osnovu modelovane relacije. Nedostajuće vrednosti atributa State popunjene su modalnom kategorijom "Standardna gradnja", dok je za Heating primenjena imputacija sa "Centralno grejanje" kao najfrekventnijom vrednošću. Nedostajući broj soba imputiran je na osnovu medijane površine po sobi (26,5 m²/sobi), primenjujući formulu: zaokruženi broj soba = površina / medijana.

Kolona Square_footage inicijalno je bila tipa object zbog prisustva sufiksa " m²"; izvršena je transformacija u numerički tip. Slično, kolona Floor sadržala je tekstualne vrednosti poput "Suteren" (mapirano na −1), "Prizemlje" (0) i "Visoko prizemlje" (0,5), koje su prevedene u numerički oblik pre konverzije.

3.3. Uklanjanje ekstremnih vrednosti

Inicijalni skup podataka sadržao je izrazite ekstremne vrednosti (eng. outliers). Sortiranjem oglasa po ceni i površini otkriveni su konkretni primeri koji ukazuju na greške pri unosu: cena od 147 milijardi EUR za stan od 125 m², površina od 128.000 m², kao i oglas sa 653 sobe i 17.300 m², karakteristike koje ne odgovaraju stambenim nekretninama. Na osnovu inspekcije raspodele i analize box plot grafika primenjena su sledeća ograničenja:

- Površina: 15 m² ≤ površina ≤ 400 m²
- Broj soba: 0 < sobe ≤ 10
- Cena: 20.000 EUR ≤ cena ≤ 2.000.000 EUR
- Cena po m²: ≤ 11.000 EUR/m²

Dodatno je primenjena korekcija za male stanove sa neproporcionalno visokim brojem soba: za stanove ispod 70 m², broj soba ograničen je na maksimum 4. Ovaj korak je uveden nakon uočavanja nelogičnih oglasa tokom EDA, na primer, stan od 44 m² sa 44 sobe koji su ili greške pri unosu ili poslovni prostori pogrešno klasifikovani kao stambeni, i koji bi značajno narušili učenje modela. Nakon svog čišćenja, skup podataka sadrži 9.489 instanci pre geokodizacije, i 8.804 instance nakon filtriranja koordinata.

3.4. Inženjering obeležja

Izveden je niz transformacija radi poboljšanja informacionog sadržaja ulaznih obeležja:

Atribut State sa 9 originalnih kategorija objedinjen je u 5 smislenih grupa kako bi se smanjila fragmentacija atributa: New (novogradnja, u izgradnji, završena izgradnja, u pripremi), Standard (standardna gradnja), Needs_renovation (izvorno stanje), Renovated (kompletna i delimična rekonstrukcija) i Luxury (lux).

Atribut Heating sa više od 50 kombinacija vrednosti transformisan je u 10 binarnih kolona koje indiciraju prisustvo pojedinih tipova grejanja (centralno, etažno na gas, etažno na struju, podno grejanje, toplotna pumpa, TA peć, kamin, klima uređaj, itd.). Ovaj pristup sačuvao je višestruke vrednosti po oglasu bez gubitka informacija.

Konačni model koristi atribut State enkodiran one-hot transformacijom zbog niske kardinalnosti i odsustva ordinalne uređenosti između kategorija. Kolona Street isključena je iz ulaza modela, gde je njena geografska informacija zamenjena numeričkim atributima koordinata i distance do centra, koji modelu daju direktno upotrebljiv prostorni signal umesto kategorijskog niza koji model ne može interno geografski da uredi.

Geokodizacijom (eng. geocoding) kolone Street dobijene su geografske koordinate (lat, lon) za svaku mikrolokaciju putem Nominatim servisa (geopy biblioteka). Na osnovu koordinata i pozicije centra Beograda (44,8167°N, 20,4600°E) izračunata je geodetska udaljenost do centra u kilometrima (dist_to_center_km) korišćenjem haversine formule, koja uzima u obzir zakrivljenost Zemljine površine. Oglasi sa koordinatama van opsega 44,6°–45,0°N i 20,2°–20,7°E isključeni su kao pogrešno geokodizovani. Atribut price_per_m2 = cena / površina deriviran je isključivo kao pomoćni atribut za eksploratorijalnu analizu i nije uključen u ulaz modela jer je direktno izveden iz ciljne promenljive (Price_EUR / Square_footage), pa bi njegovo uključivanje dovelo do curenja informacija (eng. data leakage).

4. Eksploratorna analiza podataka

4.1. Distribucija cena

Distribucija ciljne promenljive Price_EUR je pozitivno asimetrična (eng. right-skewed) sa dugim desnim repom. Srednja vrednost iznosi oko 286.583 EUR, dok je medijana 229.500 EUR, što govori o asimetriji raspodele uzrokovanoj skupim nekretninama u prestižnim lokacijama. Interkvartilni raspon kreće se od 150.000 do 340.000 EUR, što znači da se polovina oglasa nalazi u ovom cenovnom opsegu.

Distribucija cene po kvadratnom metru (price_per_m2) znatno je simetričnija i bliža normalnoj raspodeli, sa median vrednošću od oko 3.250 EUR/m² i interkvartilnim rasponom od 2.545 do 4.100 EUR/m². Maksimalna vrednost po kvadratu iznosi 10.870 EUR/m², što odgovara luksznim nekretninama u centru.

4.2. Korelaciona analiza

Matrica korelacije numeričkih atributa (Pirsonov koeficijent, eng. Pearson correlation) otkriva sledeće zavisnosti:

- Površina i cena (r = 0,80) - najjača linearna korelacija u skupu. Povećanje površine direktno povlači rast cene.
- Broj soba i površina (r = 0,78) - očekivana visoka korelacija usled međusobne zavisnosti ovih dimenzija.
- Broj soba i cena (r = 0,57) - umerena korelacija, slabija od direktnog efekta površine.
- Lift i cena per m² (r = 0,30) - prisustvo lifta pozitivno korelira sa vrednošću nekretnine po kvadratu, verovatno kao proksi za moderniju izgradnju.
- Parking i cena per m² (r = -0,11) - blaga negativna korelacija, što je intuitivno konzistentno sa činjenicom da parking mesta češće dolaze uz nekretnine u perifernim delovima gde su cene niže.

Binarne karakteristike optički internet i parking pokazuju neznatnu korelaciju sa cenom ($|r| < 0,05$), što sugerira da ovi atributi sami po sebi nisu dominantni prediktori.

4.3. Prostorna analiza - efekat lokacije

Jedna od ključnih motivacija za uvođenje geokodizovanih obeležja bila je pretpostavka o jakom uticaju lokacije na cenu nekretnine. Analiza rasejnog dijagrama cene po m² u zavisnosti od distance do centra Beograda (dist_to_center_km) jasno potvrđuje ovu pretpostavku: postoji statistički

značajna negativna linearna zavisnost - što je nekretnina udaljenija od centra, to je cena po m² niža. Regresiona linija pada sa oko 4.200 EUR/m² u zoni do 1 km od centra na ispod 2.000 EUR/m² na periferiji.

Prostorna vizualizacija svih oglasa (lat/lon → cena po m²) potvrđuje ovu prostornu heterogenost: nekretnine u centralnim zonama (Stari Grad, Vračar, Savski venac) postižu najviše cene, dok su periferne opštine (Surčin, Grocka, Sopot, Barajevo) pozicionirane u najnižem cenovnom rangu.

Zonirana analiza (Center: 0–3 km, Inner city: 3–6 km, Outer city: 6–10 km, Suburbs: >10 km) prikazuje konzistentan pad medijane cene po m² od centra ka periferiji. Centalna zona ima medijanu oko 4.200 EUR/m², unutrašnja zona grada oko 3.400 EUR/m², spoljna zona oko 2.800 EUR/m², a predgrađa oko 2.200 EUR/m². Ovi gradijenti potvrduju opravdanost deriviranog obeležja distance.

4.4. Analiza stanja i ameniteta po zonama

Analiza tipa grejanja po zonama pokazuje da je centralno grejanje ("Centralno grejanje") dominantni tip u svim zonama, sa posebno visokim udelom u centru i unutrašnjoj zoni grada, gde je udeo etažnog grejanja na gas viši nego u suburbanim oblastima. Klima uređaj kao sekundarni sistem grejanja javlja se u svim zonama, dok je toplotna pumpa relativno retka u skupu podataka.

Parking dostupnost pokazuje obrnutu zavisnost sa blizinom centru: u centralnoj zoni samo oko 22% oglasa nudi parking, dok je u predgrađima taj udeo oko 46%. Ovaj nalaz konzistentan je sa urbanim modelom gde su centralne lokacije gustije izgrađene i parking prostori ređi.

Dostupnost lifta opada sa udaljenošću od centra: u centralnoj zoni lift ima oko 63% stanova, dok je u predgrađima taj udeo svega 26%. Ovo reflektuje razliku u tipičnoj visini zgrada, jer višespratnice su predominante u centralnim delovima Beograda.

Analiza cene po m² prema stanju objekta pokazuje da kategorija Luxury i New ostvaruju neznatno više srednje cene, ali sa izraženom varijansom. Kategorija Needs_renovation (izvorno stanje) ima neznatno nižu medijanu, dok su razlike između kategorija Standard i Renovated minimalne. Ovo sugeriše da stanje objekta ima umereni doprinos ceni u poređenju sa lokacijom i površinom.

5. Metodologija i arhitektura modela

5.1. Podela podataka i pipeline

Skup podataka podeljen je na tri nepreklapajuća podskupa korišćenjem dvostruke stratifikovane slučajne podele uz fiksirani random_state=42 radi reproduktivnosti. U prvom koraku izdvojen je test skup koji čini 20% celokupnog skupa podataka - ovaj podskup nije korišćen ni u jednoj fazi treninga niti optimizacije hiperparametara i služi isključivo za finalnu evaluaciju. U drugom koraku preostali deo (80%) podeljen je u razmeri 75:25, čime su dobijeni trening skup od 5.282 instance i validacioni skup od 1.761 instance.

Finalni ulazni vektori sadrže 24 atributa: numeričke kolone (površina, broj soba, etaža, lift, optički internet, parking, lat, lon, dist_to_center_km, 10 binarnih grejanja) i jednu kategorijsku kolonu (State) enkodiranu one-hot transformacijom. Za svaki model konstruisan je sklearn.pipeline.Pipeline koji objedinjuje pretprocesiranje (ColumnTransformer) i algoritam regresije, garantujući da su transformacije primenjene na trening skupu konzistentno prenesene na validacioni i test skup bez curenja informacija.

5.2. Modeli i optimizacija hiperparametara

Implementirana su četiri modela. Linearna regresija korišćena je kao referentna osnova. Numerički atributi skaliraju se StandardScaler-om, a kategorijski se enkoduju one-hot transformacijom. Bez dodatne optimizacije hiperparametara, model je direktno trenirani na trening skupu i evaluiran na validacionom i test skupu.

Stablo odlučivanja optimizovano je postupkom nasumičnog pretraživanja (RandomizedSearchCV) sa 3-fold unakrsnom validacijom unutar trening skupa (30 kombinacija). Pretraživani prostor obuhvatio je: max_depth {4, 6, 8, 10, 12, None}, min_samples_split {2, 5, 10, 20}, min_samples_leaf {1, 2, 4, 8}, max_features {None, sqrt, log2}. Optimalni parametri: max_depth=10, min_samples_split=5, min_samples_leaf=8, max_features=None.

Random Forest Regressor optimizovan je istim postupkom (30 kombinacija, 3-fold CV unutar trening skupa). Pretraživani prostor: n_estimators {100, 200, 300, 400}, max_depth {None, 10, 20, 30, 40}, min_samples_split {2, 5, 10}, min_samples_leaf {1, 2, 4}, max_features {None, sqrt, log2}. Optimalni parametri: n_estimators=300, max_depth=None, min_samples_split=2, min_samples_leaf=1, max_features=None.

XGBoost Regressor optimizovan je nasumičnim pretraživanjem sa 50 kombinacija i 3-fold CV unutar trening skupa. Pretraživani prostor: n_estimators {200–600}, max_depth {4–10},

learning_rate {0.01–0.2}, subsample i colsample_bytree {0.6–1.0}, gamma {0–0.3}, reg_alpha i reg_lambda za regularizaciju. Optimalni parametri: n_estimators=500, max_depth=7, learning_rate=0.03, subsample=0.6, colsample_bytree=0.6, gamma=0, reg_alpha=0.1, reg_lambda=2.

Za sve modele koji koriste pretragu hiperparametara, unakrsna validacija sprovedena je isključivo unutar trening skupa. Validacioni skup korišćen je za praćenje generalizacije pre finalnog izveštavanja, dok je test skup korišćen jednokratno za finalne metrike.

5.3. Metrike evaluacije

Modeli su evaluirani primenom sledećih metrika: MAE (srednja apsolutna greška) meri prosečnu apsolutnu razliku između predikcije i stvarne vrednosti u evrima i direktno je interpretabilna; RMSE (korenska srednja kvadratna greška) penalizuje veća odstupanja jače od MAE, osetljivija je na ekstremne greške; R^2 (koeficijent determinacije) meri proporciju varijanse ciljne promenljive objašnjene modelom, pri čemu vrednosti bliže 1 ukazuju na bolji fit. Sve metrike izračunate su i na validacionom i na test skupu radi uvida u konzistentnost generalizacije.

6. Rezultati i diskusija

6.1. Poređenje performansi modela

Tabela 2 prikazuje performanse sva četiri modela na test skupu.

Model	MAE – Val (EUR)	RMSE – Val (EUR)	R^2 - Val	MAE – Test (EUR)	RMSE - Test (EUR)	R^2 - Test
Linearna regresija	73.897	125.634	0,7121	62.789	97.479	0,7620
Stablo odlučivanja	57.977	101.333	0,8127	50.983	86.792	0,8113
Random Forest	46.327	87.222	0,8612	39.684	75.937	0,8556
XGBoost	46.508	87.522	0,8603	40.534	74.469	0,8611

Tabela 2. Poređenje performansi modela na test skupu.

Rezultati pokazuju konzistentan napredak sa porastom složenosti modela. Linearna regresija postiže R^2 = 0,76 na test skupu, što je solidan rezultat koji potvrđuje prisustvo linearne komponente zavisnosti, ali je MAE od 62.789 EUR visok za praktičnu primenu. Uvođenjem stabla odlučivanja greška se smanjuje (MAE = 50.983 EUR, R^2 = 0,81), što jasno ukazuje na prisustvo nelinearnih zavisnosti u podacima.

Oba ansambl modela dominiraju po svim metrikama. Random Forest postiže MAE od 39.684 EUR i R^2 = 0,8556 na test skupu. XGBoost ostvaruje neznatno bolji RMSE (74.469 EUR naspram 75.937 EUR) i bolji R^2 (0,8611), uz nešto viši MAE (40.534 EUR). Bliska razlika između ova dva modela konzistentna je sa nalazima u literaturi [4]

Važno je napomenuti da su performanse na validacionom i test skupu međusobno konzistentne za sve modele - razlike između skupa za validaciju i test skupa su male, što potvrđuje da optimizacija hiperparametara unutar trening skupa nije dovela do prekomerne prilagođenosti i da modeli dobro generalizuju na neviđenim podacima.

Analiza reziduala ukazuje da modeli pokazuju tendenciju blagog precenjivanja nekretnina na periferiji sa luksuznom opremom. Kombinacija atributa State_Luxury i perifernih koordinata retka je u skupu podataka, zbog čega model ne može u potpunosti da razdvoji efekat stanja objekta od efekta lokacije. Visokocenovni segment (iznad 700.000 EUR) takođe je slabije zastupljen, što doprinosi višim apsolutnim greškama u tom opsegu.

6.2. Analiza važnosti atributa

Analiza važnosti atributa (eng. feature importance) sprovedena je za sva tri tree-bazirana modela. Tabela 3 prikazuje top 10 atributa prema Random Forest-u i XGBoost-u.

Rang	RF Atribut	RF Važnost	Rang	XGB Atribut	XGB Važnost
1	Square_footage	0,707	1	Square_footage	0,267
2	dist_to_center_km	0,126	2	Number_of_rooms	0,111
3	Floor	0,040	3	dist_to_center_km	0,099
4	lon	0,036	4	lon	0,077
5	lat	0,032	5	Lift	0,053
6	Number_of_rooms	0,015	6	lat	0,048
7	Lift	0,010	7	State_New	0,037
8	State_New	0,006	8	heating_Etažno grejanje na struju	0,034
9	heating_Centralno grejanje	0,005	9	Floor	0,029
10	heating_Klima uređaj	0,004	10	heating_Centralno grejanje	0,028

Tabela 3. Top 10 atributa po važnosti za Random Forest i XGBoost modele.

Random Forest pripisuje 70,7% ukupne važnosti površini, sa dominantnim primatom jednog atributa. Ovo je karakteristično za bagging metode: kada se stotine stabala grade na slučajnim podskupovima podataka i atributa, površina, kao najinformativniji prediktor, biva odabrana u ranom čvoru praktično svakog stabla, akumulirajući nesrazmerno veliku ukupnu važnost. Distanca do centra (12,6%) je drugi po važnosti atribut, dok su etaža, koordinate i broj soba u opsegu 1,5–4%.

XGBoost pokazuje znatno ravnomernije raspoređenu važnost: površina nosi 26,7%, broj soba 11,1%, distanca do centra 9,9%, longituda 7,7%, a latitude 5,3%. Ova redistribucija je efekt boosting paradigme: kada XGBoost u prvoj iteraciji modeluje efekat površine, naredne iteracije moraju koristiti preostale atribute da bi korigovale greške na rezidualima. Na taj način model efikasno iskorišćava informacioni doprinos svih atributa, a ne samo dominantnog. Posebno je zanimljivo što XGBoost identifikuje heating_Toplotna pumpa kao šesti po važnosti atribut (4,8%), signal koji Random Forest u velikoj meri ignoriše - toplotna pumpa je marker modernih, skupih nekretnina koji XGBoost prepoznaje kao suptilni cenovni signal u kombinaciji sa ostalim atributima.

Za stablo odlučivanja, površina dominira sa 76,6% važnosti, a distanca do centra sa 13,5%, što je konzistentno sa nalazima ansambl modela i potvrđuje robustnost ovih faktora.

Zajednički imenilac sva tri tree-bazirana modela je jasan: površina i lokacija (distanca do centra, koordinate) su dominantni prediktori cene nekretnina na beogradskom tržištu. Ova dva faktora zajedno objašnjavaju najveći deo varijanse cene, što je konzistentno sa ekonomskom teorijom i nalazima iz literature [5].

6.3. Diskusija nalaza i ograničenja

Ostvareni rezultati (R^2 = 0,86, RMSE ≈ 74.469–75.937 EUR) su značajno bolji od vrednosti linearne regresije i podudarni su sa nalazima srodnih istraživanja na beogradskim podacima [4]. Konzistentnost performansi između validacionog i test skupa potvrđuje validnost primenjene metodologije podele podataka i odsustvo prekomerne prilagođenost.

Jedan od ograničenja skupa podataka jeste što se radi o oglašenim cenama, a ne o realizovanim transakcijama. Prodajne transakcije mogu se razlikovati od oglašenih cena za 5–15%, što unosi sistematsku grešku u ciljnu promenljivu. Skup podataka ne uključuje godinu izgradnje objekta, što literatura [4, 5] identifikuje kao relevantan prediktor. Geokodizacija mikrolokacija može biti neprecizna za ulice sa više lokacija ili za novoizgrađene delove grada koji nisu ažurni u OpenStreetMap bazi.

Analiza prostorne distribucije otkriva da se najveća gustina oglasa nalazi u centralnoj i unutrašnjoj zoni Beograda (do 6 km od centra), dok su predgrađa zastupljena znatno manjim brojem uzoraka. Ovo može uzrokovati slabije performanse modela za suburbane nekretnine. Buduće iteracije trebalo bi da uključe stratifikaciju po zonama pri podeli skupa radi jednake zastupljenosti u trening skupu.

Napominjemo i da je ciljna funkcija optimizacije bila R^2 (ekvivalent minimizaciji MSE), a ne MAE. Zbog toga je neznatno viši MAE XGBoost-a u odnosu na Random Forest (40.534 EUR naspram 39.684 EUR) rezultat optimizacione asimetrije - model je podešen da minimizuje kvadratne greške, pa manje kažnjava prosečna odstupanja, dok se prednost XGBoost-a ogleda u RMSE metrici.

7. Zaključak

U ovom radu razvijeni su i upoređeni modeli mašinskog učenja za predikciju prodajne cene stambenih nekretnina na beogradskom tržištu. Na skupu od 8.804 oglasa, podeljenom na trening (60%), validacioni (20%) i test (20%) podskup, sa geokodizovanim koordinatama i deriviranom distancom do centra Beograda kao dodatnim atributima, postignuti su sledeći rezultati:

- Ansambl modeli (Random Forest, XGBoost) ostvaruju $R^2 = 0{,}86$ i RMSE u opsegu 74.469–75.937 EUR na test skupu, što je značajno bolje od linearne regresije ($R^2 = 0{,}76$, RMSE = 97.479 EUR) i stabla odlučivanja ($R^2 = 0{,}81$, RMSE = 86.792 EUR)
- Površina stana i udaljenost od centra Beograda identifikovane su kao dominantni prediktori cene u svim tree
- baziranim modelima, uz konzistentan nalaz između stabla odlučivanja, Random Forest-a i XGBoost-a.
- Geokodizacija mikrolokacija i derivacija distance do centra pokazale su se kao vredna obogaćivanja skupa podataka koja modelu pružaju direktno upotrebljiv prostorni signal.
- XGBoost je ostvario blagu prednost u RMSE metrici (74.469 EUR naspram 75.937 EUR) uz ravnomernije raspoređenu važnost atributa, dok je Random Forest postigao nešto niži MAE. Oba modela pokazuju dobru generalizaciju, sa konzistentnim performansama između validacionog i test skupa.
- Primena trodelne podele podataka i striktno odvajanje test skupa od procesa optimizacije hiperparametara osigurava nepristrasnu finalnu evaluaciju i validnost prijavljenih metrika.

Ovi rezultati potvrđuju opravdanost primene nelinearnih ansambl metoda za modelovanje kompleksnih tržišta nekretnina i ukazuju da cena nije samo linearna funkcija veličine stana, već kompleksna interakcija između prostornih, fizičkih i infrastrukturnih karakteristika.

Kao pravce budućeg rada predlažemo: (1) uključivanje godine izgradnje i podataka o renovacijama kao dodatnih prediktor; (2) primenu naprednih prostornih modela koji direktno modeluju prostornu autokorelaciju cena; (3) obogaćivanje skupa podacima o realizovanim transakcijama umesto oglasa i (4) razvoj interaktivnog veb alata koji bi korisnicima omogućio unos karakteristika nekretnine i dobijanje procene cene u realnom vremenu.

Literatura

[1] Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32.

[2] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of KDD 2016, 785–794.

[3] Tibshirani, R., Friedman, J., & Hastie, T. (2009). The Elements of Statistical Learning. Springer.

[4] Perić, M., et al. (2024). Housing price prediction using XGBoost and Random Forest methods. EBM 2024. https://doi.ub.kg.ac.rs/doi/zbornici/ebm24-417m/

[5] Čeh, M., et al. (2018). Estimating the Performance of Random Forest versus Multiple Regression for Predicting Prices of Apartments. ISPRS International Journal of Geo-Information, 7(5), 168. https://www.mdpi.com/2220-9964/7/5/168

[6] Valsts A., et al. (2023). Predicting real estate prices with machine learning. Vilnius University. https://epublications.vu.lt/object/elaba:229583156/229583156.pdf

[7] Antipov, E. A., & Pokryshevskaya, E. B. (2023). The Use of Machine Learning in Real Estate Research. Land, 12(4), 740. https://www.mdpi.com/2073-445X/12/4/740